

Mejora del Contexto de un LLM en Entornos Dinámicos utilizando Modelos Basados en Agentes (ABM)

Propuesta de Proyecto Computacional Guiado

Alumno: Walter Andrés Zárate Solar

Profesor: Pedro Pinacho Davidson

1. Introducción y Planteamiento del Problema

El uso de Modelos de Lenguaje de Gran Escala (LLM) como agentes autónomos en entornos interactivos enfrenta un cuello de botella crítico: la gestión eficiente y persistente del contexto histórico. Acumular el historial de observaciones linealmente satura rápidamente la ventana de contexto del modelo. Esto conduce a una degradación contextual (*context rot*), lo que incrementa el costo computacional y provoca alucinaciones frecuentes sobre el estado real del mundo. Por otra parte, los enfoques tradicionales como la Generación Aumentada por Recuperación (RAG) vectorial resultan insuficientes, ya que no logran capturar las relaciones lógicas ni espaciales en entornos con dependencias causales.

2. Propuesta y Enfoque de Investigación

El objetivo principal de esta investigación es formular, implementar y evaluar una arquitectura de memoria externa dinámica. En lugar de utilizar enfoques estáticos como los grafos de conocimiento entidad-relación, se propone estructurar esta memoria como una simulación viva mediante un Modelo Basado en Agentes (ABM). Esta simulación no es solo información inerte; posee lógica interna donde los eventos ocurren y evolucionan, actuando como el cerebro externo del agente LLM principal que intenta resolver el entorno.

El trabajo se estructurará en torno a los siguientes ejes exploratorios:

- **Estado del Arte y Arquitectura:** Investigar las metodologías actuales para definir las mejores estrategias de acoplamiento entre un agente LLM y un ABM.
- **Extracción e Interacción Dinámica:** Explorar y definir cómo el LLM consultará y modificará este simulador por turnos.
- **Evaluación y Puntos Frágiles:** Utilizar TextWorld como *sandbox* estandarizado de pruebas para someter al agente a tareas concretas, identificando empíricamente los puntos frágiles y cuellos de botella de la arquitectura propuesta.
- **Definición de Métricas:** Se medirá el rendimiento del agente en el entorno en términos de velocidad, precisión, gasto de tokens, consistencia, recuperación de contexto y reducción de alucinaciones frente a las líneas base convencionales. Además de otras métricas que se descubran en el camino y se consideren relevantes.

3. Resultados Esperados y Entregables

Al ser un proyecto de naturaleza exploratoria, los entregables se centrarán en demostrar la viabilidad y el rendimiento del concepto en un entorno controlado. Al finalizar el semestre, se espera consolidar el trabajo en los siguientes productos:

- **Prototipo Funcional (Repositorio de Código):** Un *software* prototipo que implemente la arquitectura propuesta, acoplando el agente LLM con la simulación ABM. Este código estará integrado con el *sandbox* TextWorld para demostrar el concepto en acción e incluirá los *scripts* necesarios para replicar los experimentos.
- **Informe de Investigación y Evaluación:** Un documento detallado que exponga el análisis del estado del arte, justifique las decisiones de diseño de la arquitectura final y presente empíricamente los resultados, métricas y puntos frágiles descubiertos durante la exploración en TextWorld.
- **Presentaciones y Reportes de Avance:** Entregas parciales durante el semestre que incluirán la presentación de un Plan de Trabajo inicial y resúmenes periódicos de los descubrimientos arquitectónicos y experimentales.